


对话(Chat) API

火山方舟



法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
(周一至周五 10:00-18:00)

目录

法律声明-----1

目录-----1

1. 对话(Chat) API-----1

1. 对话(Chat) API

POST <https://ark.cn-beijing.volces.com/api/v3/chat/completions> [运行](#)

发送包含文本、图片、视频等模态的消息列表，模型将生成对话中的下一条消息。

Tips：一键展开折叠，快速检索内容

说明

打开页面右上角开关后，**ctrl** + f 可检索页面内所有内容。

展开本文档内所有折叠内容



我的收藏



有用



无用

在线调试

API Explorer

[去调试](#)

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)

[开通模型](#) [文本生成](#) [视觉理解](#) [接口文档](#)

请求参数

[跳转](#) [响应参数](#)

请求体

model string 必选

调用的模型 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

多个应用及精细管理场景，推荐使用 Endpoint ID 调用。详细请参考[获取 Endpoint ID](#)。

messages `object[]` 必选

消息列表，不同模型支持不同类型的消息，如文本、图片、视频等。

消息类型

系统消息 `object`

模型需遵循的指令，包括扮演的角色、背景信息等。

属性

messages.role `string` 必选

发送消息的角色，此处应为 `system` 。

messages.content `string / object[]` 必选

系统消息的内容。

属性

纯文本内容 `string`

纯文本消息内容。

多模态内容 `object[]`

各模态内容对象

文本部分 `object`

属性

messages.content.text**** `string` 必选

文本模态部分的内容。

messages.content.type**** `string` 必选

内容模态，此处应为 `text` 。

图片部分 `object`

属性

`messages.content.**image_url**` `object` 必选

图片模态的内容。

属性

`messages.content.image_url.**url**` `string` 必选

支持格式如下，详细信息请参见[使用说明](#)。

- 图片链接
- 图片的Base64编码

`messages.content.image_url.**detail**` `string`

取值范围：`low`、`high`、`xhigh`。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

`messages.content.**type**` `string` 必选

内容模态，此处应为 `image_url`。

视频部分 `object`

不支持理解视频中的音频内容。

属性

`messages.content.**type**` `string` 必选

内容模态，此处应为 `video_url`。

`messages.content.video_url` `object` 必选

视频消息的内容部分。

属性

`messages.content.video_url.**url**` `string` 必选

支持格式如下，具体使用请参见[视频理解说明](#)。

- 视频链接

- 视频的Base64编码

`messages.content.video_url.fps` float/ null 默认值 1

取值范围: [0.2, 5]

抽帧频率, 详见[视频理解](#)。

- 取值越高, 对视频中画面变化越敏感。
- 取值越低, 对视频中画面变化越迟钝, 但 token 花费少, 速度更快。

用户消息 `object`

用户角色发送的消息。不同模型支持的字段类型不同。

属性

`messages.role` string 必选

发送消息的角色, 此处应为 `user`。

`messages.content` string / object[] 必选

用户信息内容。

内容类型

纯文本内容 `string`

纯文本消息内容。

多模态内容 `object[]`

支持文本、图片、视频等模态内容。

内容类型

文本部分 `object`

多模态消息中, 文本模态的部分。

属性

`messages.content.**text**` string 必选

文本模态部分的内容。

messages.content.**type** string 必选

内容模态，此处应为 text。

图片部分 object

属性

messages.content.**type** string 必选

消息模态，此处应为 image_url。

messages.content.**image_url** object 必选

图片模态的内容。

属性

messages.content.image_url.**url** string 必选

支持格式如下，具体请参见[使用说明](#)。

- 图片链接
- 图片的Base64编码

messages.content.image_url.**detail** string / null

取值范围：low、high、xhigh。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

messages.content.image_url.**image_pixel_limit** object / null 默认值 null

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

注意

图片像素范围需在 [196, 36,000,000]，否则会直接报错。

- 生效优先级：高于 **detail** 字段，即同时配置 **detail** 与 **image_pixel_limit** 字段时，生效 **image_pixel_limit** 字段配置。
- 默认生效规则：若未设置 image_pixel_limit，则使用 **detail** 配置的值对应的 **min_pixels** / **max_pixels** 值。

· `messages.content.image_url.image_pixel_limit.**max_pixels**` `integer`
传入图片最大像素限制，大于此像素则等比例缩小至 `**max_pixels**` 字段取值以下。若未设置，则取值为 `**detail**` 配置的值对应的 `**max_pixels**` 值。

- doubao-seed-1.8 之前的模型取值范围：(`min_pixels`, `4014080`]
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：(`min_pixels`, `9031680`]。

· `messages.content.image_url.image_pixel_limit.**min_pixels**` `integer`
传入图片最小像素限制，小于此像素则等比例放大至 `**min_pixels**` 字段取值以上。若未设置，则取值为 `**detail**` 配置的值对应的 `**min_pixels**` 值。

- doubao-seed-1.8 之前的模型取值范围：[`3136`, `max_pixels`)
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[`1764`, `max_pixels`)

视频部分 `object`

不支持理解视频中的音频内容。

属性

`messages.content.**type**` `string` 必选
内容模态，此处应为 `video_url`。

`messages.content.video_url` `object` 必选
视频模态的内容。

属性

`messages.content.video_url.**url**` `string` 必选
支持格式如下，具体使用请参见[视频理解说明](#)。

- 视频链接
- 视频的Base64编码

`messages.content.video_url.fps` `float/ null` 默认值 1
取值范围：[`0.2`, `5`]。
抽帧频率，详见[视频理解](#)。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

模型消息 `object`

历史对话中，模型角色返回的消息。用以保持对话一致性，多在[多轮对话](#)及[续写模式](#)使用。

属性

说明

`messages.content` 与 `messages.tool_calls` 至少填写其一。

`messages.role` `string` 必选

发送消息的角色，此处应为 `assistant`。

`messages.content` `string / array`

模型消息的内容。

`messages.reasoning_content` `string`

模型消息中思维链内容。

仅模型 `doubao-seed-1.8`、`deepseek-v3.2`、`doubao-seed-2.0` 支持该字段。

`messages.tool_calls` `object[]`

模型消息中工具调用部分。

属性

`messages.tool_calls.function` `object` 必选

模型返回的需调用的函数信息。

属性

`messages.tool_calls.function.name` `string` 必选

需调用的函数的名称。

`messages.tool_calls.function.arguments` `string` 必选

需调用的函数的入参，JSON 格式。

说明

模型并不总是生成有效的 JSON，可能会虚构出未定义的参数。建议在调用函数前，验证参数是否有效。

`messages.tool_calls **.id ** string` 必选
需调用的工具的 ID，由模型生成。

`messages.tool_calls **.type ** string` 必选
消息类型，当前仅支持 `function`。

工具消息 `object`
历史对话中，调用工具返回的消息。工具调用场景中使用。

属性

`messages.role string` 必选
发送消息的角色，此处应为 `tool`。

`messages.content string / array` 必选
工具返回的消息。

`messages.**tool_call_id ** string` 必选
模型生成的需调用工具请求时，生成的ID。在程序调用工具的返回需要附上同一 ID，来关联工具结构与模型请求。避免多工具调用时混淆信息。

`thinking object` 默认值 `{"type": "enabled"}`
控制模型是否开启深度思考模式。

不同模型是否支持以及默认取值不同，详情请查询[文档](#)。

属性

`thinking.**type ** string` 必选
取值范围：`enabled`，`disabled`，`auto`。

- `enabled`：开启思考模式，模型强制先思考再回答。

- `disabled` : 关闭思考模式, 模型直接回答问题, 不进行思考。
- `auto` : 自动思考模式, 模型根据问题自主判断是否需要思考, 简单题目直接回答。

stream `boolean / null` 默认值 `false`

响应内容是否流式返回:

- `false` : 模型生成完所有内容后一次性返回结果。
- `true` : 按 SSE 协议逐块返回模型生成内容, 并以一条 `data: [DONE]` 消息结束。当 **stream** 为 `true` 时, 可设置 **stream_options** 字段以获取 token 用量统计信息。

stream_options `object / null` 默认值 `null`

流式响应的选项。当 **stream** 为 `true` 时, 可设置 **stream_options** 字段。

属性

stream_options.include_usage**** `boolean / null` 默认值 `false`

模型流式输出时, 是否在输出结束前输出本次请求的 token 用量信息。

- `true` : 在 `data: [DONE]` 消息之前会返回一个额外的 chunk。此 chunk 中, **usage** 字段中输出整个请求的 token 用量, **choices** 字段为空数组。
- `false` : 输出结束前, 没有一个 chunk 来返回 token 用量信息。

stream_options.chunk_include_usage**** `boolean / null` 默认值 `false`

模型流式输出时, 输出的每个 chunk 中是否输出本次请求到此 chunk 输出时刻的累计 token 用量信息。

- `true` : 在返回的 **usage** 字段中, 输出本次请求到此 chunk 输出时刻的累计 token 用量。
- `false` : 不在每个 chunk 都返回 token 用量信息。

max_tokens `integer / null` 默认值 4096

取值范围: 各个模型不同, 详细见[模型列表](#)。

模型回答最大长度 (单位 token)。

说明

- 模型回答不包含思维链内容, 模型回答 = 模型输出 - 模型思维链 (如有)
- 输出 token 的总长度还受模型的上下文长度限制。

max_completion_tokens `integer / null`

支持该字段的模型及使用说明见 [文档](#)。

取值范围： `[1,65,536]` 。

控制模型输出的最大长度（包括模型回答和模型思维链内容长度，单位 token ）。

配置了该参数后，可以让模型输出超长内容，**`max_tokens`

默认值失效，模型按需输出内容（回答和思维链），直到达到**`max_completion_tokens`** 值。

不可与 `max_tokens` 字段同时设置。

service_tier `string / null` 默认值 `auto`

控制是否使用TPM保障包 。取值范围： `auto` 、 `default` 。

- `auto` ：本次请求优先使用 TPM 保障包额度。
 - 有 TPM 保障包额度的推理接入点，本次请求将会优先使用 TPM 保障包额度，获得更高的服务等级（响应速度、可用性）。
 - 无 TPM 保障包额度或用超额度的推理接入点，维持默认的服务等级。
- `default` ：本次请求不使用 TPM 保障包，维持默认的服务等级（即使推理接入点有TPM保障包额度）。

stop `string / string[] / null` 默认值 `null`

模型遇到 `stop` 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。

[深度思考能力模型](#) 不支持该字段。

`["你好","天气"]`

reasoning_effort `string / null` 默认值 `medium`

支持该字段的模型、与 `thinking.type` 字段关系见[文档](#)。

限制思考的工作量。减少思考深度可提升速度，思考花费的 token 更少。

取值范围： `minimal` ， `low` ， `medium` ， `high` 。

- `minimal` ：关闭思考，直接回答。
- `low` ：轻量思考，侧重快速响应。
- `medium` ：均衡模式，兼顾速度与深度。
- `high` ：深度分析，处理复杂问题。

response_format `object` 默认值 `{"type": "text"}` `beta阶段`

指定模型回答格式。

回答格式说明

文本格式 `object`

模型默认回复文本格式内容。

属性

`response_format.type` `string` 必选

此处应为 `text`。

JSON Object 格式 `object`

模型回复内容以JSON对象结构来组织。

支持该字段的模型请参见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

`response_format.**type**` `string` 必选

此处应为 `json_object`。

JSON Schema 格式 `object`

模型回复内容以JSON对象结构来组织，遵循 `**schema**` 字段定义的JSON结构。

支持该字段的模型请参见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

`response_format.**type**` `string` 必选

此处应为 `json_schema`。

`response_format.json_schema` `object` 必选

JSON结构体的定义。

属性

`response_format.json_schema.name` `string` 必选

用户自定义的JSON结构的名称。

response_format.json_schema.description string / null

回复用途描述，模型将根据此描述决定如何以该格式回复。

response_format.json_schema.schema object 必选

回复格式的 JSON 格式定义，以 JSON Schema 对象的形式描述。

response_format.json_schema.strict boolean / null 默认值 false

是否在生成输出时，启用严格遵循模式。

- **true**：模型将始终严格遵循**schema**字段中定义的格式。
- **false**：模型会尽可能遵循**schema**字段中定义的结构。

frequency_penalty float / null 默认值 0

取值范围为 [-2.0 , 2.0]。

频率惩罚系数。如值为正，根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。

presence_penalty float / null 默认值 0

取值范围为 [-2.0 , 2.0]。

存在惩罚系数。如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。

temperature float / null 默认值 1

取值范围为 [0 , 2]。

注意

当调用下列模型，字段取值固定为 **1**，手动指定的参数值将被忽略。

- **doubao-seed-2-0-pro-260215**
- **doubao-seed-2-0-lite-260215**

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。

通常建议仅调整 temperature 或 top_p 其中之一，不建议两者都修改。

top_p float / null 默认值 0.7

取值范围为 [0 , 1]。

注意

当调用下列模型，字段取值固定为 `0.95`，手动指定的参数值将被忽略。

- `doubao-seed-2-0-pro-260215`
- `doubao-seed-2-0-lite-260215`

核采样概率阈值。模型会考虑概率质量在 `top_p` 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。通常建议仅调整 `temperature` 或 `top_p` 其中之一，不建议两者都修改。

logprobs `boolean / null` 默认值 `false`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

是否返回输出 tokens 的对数概率。

- `false`：不返回对数概率信息。
- `true`：返回消息内容中每个输出 token 的对数概率。

top_logprobs `integer / null` 默认值 `0`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

取值范围为 `[ 0 , 20 ]`。

指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 **logprobs** 为 `true` 时可以设置 **top_logprobs** 参数。

logit_bias `map / null` 默认值 `null`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。**logit_bias** 字段接受一个 map 值，其中每个键为词表中的 token ID（使用 `tokenization` 接口获取），每个值为该 token 的偏差值，取值范围为 `[-100, 100]`。

-1 会减少选择的可能性，1 会增加选择的可能性；-100 会完全禁止选择该 token，100 会导致仅可选择该 token。该参数的实际效果可能因模型而异。

```
{"<Token_ID>": -100}
```

tools `object[] / null` 默认值 `null`

待调用工具的列表，模型返回信息中可包含。当您需要让模型返回待调用工具时，需要配置该结构体。支持该字段的模型请参见[文档](#)。

属性

`tools.**type**` `string` 必选
工具类型，此处应为 `function`。

`tools.**function**` `object` 必选
模型返回中可包含待调用的工具。

属性

`tools.function.**name**` `string` 必选
调用的函数的名称。

`tools.function.**description**` `string`
调用的函数的描述，大模型会使用它来判断是否调用这个工具。

`tools.function.**parameters**` `object`
函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档，格式如下：

JSON

```
{
  "type": "object",
  "properties": {
    "参数名": {
      "type": "string | number | boolean | object | array",
      "description": "参数说明"
    }
  },
  "required": ["必填参数"]
}
```

其中，

- 所有字段名大小写敏感。
- **parameters** 须是合规的 JSON Schema 对象。
- 建议用英文字段名，中文置于 **description** 字段中。

parallel_tool_calls `boolean` 默认值 `true`

本次请求，模型返回是否允许包含多个待调用的工具。

- `true` : 允许返回多个待调用的工具。
- `false` : 允许返回的待调用的工具小于等于1，本取值在 `doubao-seed-1.6` 及之后系列模型生效。

tool_choice `string / object`

仅 `doubao-seed-1.6` 及之后系列模型支持此字段。

本次请求，模型返回信息中是否有待调用的工具。

当没有指定工具时，`none` 是默认值。如果存在工具，则 `auto` 是默认值。

可选类型

选择模式 `string`

控制模型返回是否包含待调用的工具。

- `none` : 模型返回信息中不可含有待调用的工具。
- `required` : 模型返回信息中必须含待调用的工具。选择此项时请确认存在适合的工具，以减少模型产生幻觉的情况。
- `auto` : 模型自行判断返回信息是否有待调用的工具。

工具调用 `object`

指定待调用工具的范围。模型返回信息中，只允许包含以下模型信息。选择此项时请确认该工具适合用户需求，以减少模型产生幻觉的情况。

属性

tool_choice.type `string` `%%require%%`

调用的类型，此处应为 `function` 。

tool_choice.function `object` `%%require%%`

调用工具的信息。

属性

tool_choice.function **.name ** `string` `%%require%%`

待调用工具的名称。

响应参数

跳转 [请求参数](#)

非流式调用返回

跳转 [流式调用返回](#)

id `string`

本次请求的唯一标识。

model `string`

本次请求实际使用的模型名称和版本。

service_tier `string`

本次请求是否使用了TPM保障包。

- `scale` : 本次请求使用TPM保障包额度。
- `default` : 本次请求未使用TPM保障包额度。

created `integer`

本次请求创建时间的 Unix 时间戳（秒）。

object `string`

固定为 `chat.completion`。

choices `object[]`

本次请求的模型输出内容。

属性

`choices.**index**` `integer`

当前元素在 **choices** 列表的索引。

`choices.**finish_reason**` `string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
- `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
 - 触发 `max_tokens` 限制（回答内容的长度限制）。
 - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。

◦ 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。

- `content_filter`：模型输出被内容审核拦截。
- `tool_calls`：模型调用了工具。

`choices.**message**` `object`
模型输出的内容。

属性

`choices.message.**role**` `string`
内容输出的角色，此处固定为 `assistant`。

`choices.message.**content**` `string`
模型生成的消息内容。

`choices.message.**reasoning_content**` `string / null`
模型处理问题的思维链内容。
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。

`choices.message.**tool_calls**` `object[] / null`
模型生成的工具调用。

属性

`choices.message.tool_calls.id**` `string`
调用的工具的 ID。

`choices.message.tool_calls.**type**` `string`
工具类型，当前仅支持 `function`。

`choices.message.tool_calls.**function**` `object`
模型调用的函数。

属性

`choices.message.tool_calls.function.**name` **string**

模型调用的函数的名称。

`choices.message.tool_calls.function.**arguments` **string**

模型生成的用于调用函数的参数，JSON 格式。

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`choices.**logprobs` **object / null**

当前内容的对数概率信息。

属性

`choices.logprobs.**content` **object[] / null**

message列表中每个 content 元素中的 token 对数概率信息。

属性

`choices.logprobs.content.**token` **string**

当前 token。

`choices.logprobs.content.**bytes` **integer[] / null**

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.**logprob` **float**

当前 token 的对数概率。

`choices.logprobs.content.**top_logprobs` **object[]**

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 top_logprobs 指定的数量要少。

属性

`choices.logprobs.content.top_logprobs.**token` **string**

当前 token。

choices.logprobs.content.top_logprobs.**bytes** integer[] / null

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

choices.logprobs.content.top_logprobs.**logprob** float

当前 token 的对数概率。

choices.**moderation_hit_type** string/ null

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。
- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者[CreateEndpoint](#)接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

usage object

本次请求的 token 用量。

属性

usage.**total_tokens** integer

本次请求消耗的总 token 数量（输入 + 输出）。

usage.**prompt_tokens** integer

输入给模型处理的内容 token 数量。

usage.**prompt_tokens_details** object

输入给模型处理的内容 token 数量的细节。

属性

usage.prompt_tokens_details.**cached_tokens** integer

缓存输入内容的 token 用量，此处应为 0。

usage.completion_tokens `integer`
模型输出内容花费的 token。

usage.completion_tokens_details `object`
模型输出内容花费的 token 的细节。

属性

usage.completion_tokens_details.reasoning_tokens `integer`
输出思维链内容花费的 token 数。
支持输出思维链的模型请参见[文档](#)。

流式调用返回

跳转 [非流式调用返回](#)

id `string`
本次请求的唯一标识。

model `string`
本次请求实际使用的模型名称和版本。

service_tier `string`
本次请求是否使用了TPM保障包。

- **scale** : 本次请求使用TPM保障包额度。
 - **default** : 本次请求未使用TPM保障包额度。
-

created `integer`
本次请求创建时间的 Unix 时间戳（秒）。

object `string`
固定为 `chat.completion.chunk`。

choices `object[]`

本次请求的模型输出内容。

属性

choices.index**** `integer`

当前元素在 **choices** 列表的索引。

choices.finish_reason**** `string`

模型停止生成 token 的原因。取值范围：

- **stop** : 模型输出自然结束，或因命中请求参数 **stop** 中指定的字段而被截断。
 - **length** : 模型输出因达到模型输出限制而被截断，有以下原因：
 - 触发 **max_tokens** 限制（回答内容的长度限制）。
 - 触发 **max_completion_tokens** 限制（思维链内容+回答内容的长度限制）。
 - 触发 **context_window** 限制（输入内容+思维链内容+回答内容的长度限制）。
 - **content_filter** : 模型输出被内容审核拦截。
 - **tool_calls** : 模型调用了工具。
-

choices.delta**** `object`

模型输出的增量内容。

属性

choices.delta.role**** `string`

内容输出的角色，此处固定为 **assistant** 。

choices.delta.content**** `string`

模型生成的消息内容。

choices.delta.reasoning_content**** `string / null`

思考内容原文。

仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。

choices.delta.tool_calls**** `object[] / null`

模型生成的工具调用。

属性

`choices.delta.tool_calls.**id**` `string`
调用的工具的 ID。

`choices.delta.tool_calls.**type**` `string`
工具类型，当前仅支持 `function` 。

`choices.delta.tool_calls.**function**` `object`
模型调用的函数。

属性

`choices.delta.tool_calls.function.**name**` `string`
模型调用的函数的名称。

`choices.delta.tool_calls.function.**arguments**` `string`
模型生成的用于调用函数的参数，JSON 格式。
模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`choices.**logprobs**` `object / null`
当前内容的对数概率信息。

属性

`choices.logprobs.**content**` `object[] / null`
message列表中每个 `content` 元素中的 token 对数概率信息。

属性

`choices.logprobs.content.**token**` `string`
当前 token。

`choices.logprobs.content.**bytes**` `integer[] / null`
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.**logprob` **float**

当前 token 的对数概率。

`choices.logprobs.content.**top_logprobs` **object[]**

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。

属性

`choices.logprobs.content.top_logprobs.**token` **string**

当前 token。

`choices.logprobs.content.top_logprobs.**bytes` **integer[] / null**

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.top_logprobs.**logprob` **float**

当前 token 的对数概率。

`choices.**moderation_hit_type` **string / null**

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。
- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

`usage` **object**

本次请求的 token 用量。

流式调用时，默认不统计 token 用量信息，返回值为 `null`。

如需统计，需设置 `stream_options.include_usage` 为 `true`。

属性

usage.**total_tokens ** integer

本次请求消耗的总 token 数量（输入 + 输出）。

usage.**prompt_tokens ** integer

输入给模型处理的内容 token 数量。

usage.**prompt_tokens_details ** object

输入给模型处理的内容 token 数量的细节。

属性

usage.prompt_tokens_details.**cached_tokens ** integer

缓存输入内容的 token 用量，此处应为 0 。

usage.**completion_tokens ** integer

模型输出内容花费的 token。

usage.**completion_tokens_details ** object

模型输出内容花费的 token 的细节。

属性

usage.completion_tokens_details.**reasoning_tokens ** integer

输出思维链内容花费的 token 数。

支持输出思维链的模型请参见[文档](#) .